

INFORME DE CALIDAD DE DATOS PARA NOVAMARKET

Juan Esteban Camacho Castro

Juan Diego Serpa Ruiz

Universidad de La Sabana

Agosto 2026

1. Informe ejecutivo

El análisis de calidad del dataset de NovaMarket evidenció un nivel general de confiabilidad medio. Si bien la información permite realizar análisis generales, se identificaron problemas que limitan su uso en procesos críticos y en la toma de decisiones.

El principal hallazgo corresponde a la oportunidad de la información de inventario, con una alta proporción de registros con más de 90 días sin actualización. También se encontraron inconsistencias en variables como `metodo_pago` y `nivel_satisfaccion`, además de valores faltantes, registros duplicados y datos que no cumplen con los rangos o formatos esperados.

Se recomienda priorizar la actualización del inventario, estandarización de variables, validación de datos y depuración de duplicados antes de utilizar el dataset en reportes críticos, modelos analíticos o decisiones operativas.

2. Alcance y metodología

El análisis se realizó sobre el dataset “**NovaMarket_datos_crudos.csv**”, compuesto por 640.000 filas y 18 columnas, con el objetivo de evaluar la calidad de la información e identificar posibles riesgos para su uso en análisis y toma de decisiones.

La evaluación se realizó mediante **Python**, considerando las siguientes seis dimensiones:

- **Compleitud:** verifica la presencia de información requerida e identifica valores faltantes.
- **Exactitud:** evalúa si los datos representan valores razonables de acuerdo con el contexto del negocio.
- **Consistencia:** comprueba que los datos mantengan una representación uniforme y sin contradicciones.
- **Validez:** verifica que los datos cumplan con los formatos, rangos y reglas establecidos.
- **Unicidad:** identifica registros duplicados que puedan generar un doble conteo de la información.

- **Oportunidad:** determina si los datos se encuentran actualizados y disponibles para su uso en el momento requerido.

Los resultados de cada dimensión se expresaron mediante el **número y porcentaje de registros afectados**, permitiendo identificar los principales problemas de calidad y su impacto potencial en el negocio.

3. Hallazgos por dimensión

3.1 Completitud

Se identificaron 105.315 faltantes en correo_cliente (16,46%), 90.806 en comentario_cliente (14,19%), 46.469 en nivel_satisfaccion (7,26%), 29.928 en ciudad_tienda (4,68%) y 21.640 en precio_unitario y monto_compra (3,38% cada uno). Estos faltantes provienen principalmente de campos de información comercial y de clientes, y pueden limitar la segmentación, el análisis de satisfacción y el estudio del comportamiento de compra.

3.2 Exactitud

Se detectaron 19.629 precios negativos (3,07%), 3.164 precios superiores a \$10.000.000 (0,96%), 18.550 unidades vendidas negativas (2,90%), 27.829 edades fuera del rango establecido (4,35%) y 18.526 pedidos con más de 100 unidades (2,89%). Estos valores provienen de registros que incumplen reglas de negocio y pueden distorsionar indicadores de ventas, ingresos y perfil de clientes.

3.3 Consistencia

Se encontraron 129.372 registros inconsistentes en metodo_pago (20,21%) y 95.706 en nivel_satisfaccion (14,95%), originados principalmente por diferencias de escritura, mayúsculas, tildes y formatos; también se presentaron casos similares en ciudad y categoría de producto. Estas inconsistencias fragmentan las categorías y pueden generar conteos y segmentaciones incorrectas.

3.4 Validez

Se identificaron 17.061 registros con fechas inválidas (2,67%) y 51.532 correos sin el símbolo @ (8,05%), provenientes del incumplimiento de los formatos definidos para estos campos. Esto puede afectar los análisis temporales y reducir la confiabilidad de los procesos de contacto y segmentación de clientes.

3.5 Unicidad

Se detectaron 20.000 registros con id_pedido duplicado (3,12%) y 20.000 filas completamente duplicadas (3,12%), provenientes de la repetición de transacciones en el dataset. Estos duplicados pueden generar un doble conteo y sobreestimar indicadores como pedidos, unidades vendidas e ingresos.

3.6 Oportunidad

Se encontraron 16.485 registros con fecha_pedido posterior a la fecha de corte (2,58%) y 350.611 registros de inventario con más de 90 días sin actualización (54,78%), además de 21.722 actualizaciones posteriores al corte (3,39%). Estos problemas evidencian información desactualizada o temporalmente inconsistente y pueden afectar decisiones de inventario, reposición, disponibilidad y rotación de productos.

4. Catálogo de problemas priorizado

Problema	Registros afectados	Prioridad
Stock sin actualizar mayor a 90 días	350.611 (54,78 %)	Alta
metodo_pago inconsistente	129.372 (20,21 %)	Alta
Datos faltantes en correo_cliente	105.312 (16,46 %)	Alta
nivel_satisfaccion inconsistente	95.706 (14,95 %)	Alta
Correos sin @	51.532 (8,05 %)	Alta
Fechas de stock futuras	21.722 (3,39 %)	Alta
Filas duplicadas	20.000 (3,12 %)	Alta
id_pedido con duplicado	20.000 (3,12 %)	Alta
Precios negativos	19.629 (3,07 %)	Alta
Unidades negativas	18.550 (2,90 %)	Alta
Fechas inválidas	17.061 (2,67 %)	Alta
Fechas de pedido futuras	16.485 (2,58 %)	Alta
Datos faltantes en comentario_cliente	90.806 (14,19 %)	Media
Datos faltantes en nivel_satisfaccion	46.469 (7,26 %)	Media
Datos faltantes en ciudad_tienda	29.928 (4,68 %)	Media
Edades fuera de iguales a 0 y mayores a 120	27.829 (4,35 %)	Media

Pedidos con más de 100 unidades	18.526 (2,89 %)	Media
Precios mayores \$10.000.000	6.164 (0,96 %)	Media

5. Conclusión de confiabilidad

El dataset de NovaMarket presenta un nivel de confiabilidad medio. Aunque contiene información suficiente para realizar análisis generales, los hallazgos evidencian problemas relevantes de calidad, especialmente en oportunidad, consistencia, completitud y unicidad. El principal riesgo corresponde a la información de inventario, donde el 54,78% de los registros presenta más de 90 días sin actualización, lo que puede afectar directamente las decisiones operativas.

Por lo anterior, se recomienda priorizar la actualización del inventario, la estandarización de variables, la corrección de valores inválidos y la eliminación de duplicados antes de utilizar el dataset en reportes críticos, modelos analíticos o decisiones estratégicas. Con estas acciones, la base podría alcanzar un nivel de confiabilidad adecuado para su uso operativo y analítico.