

PLAN DE SANEAMIENTO

NovaMarket

Integrantes: Juan Diego Serpa Ruiz, Juan Esteban Camacho Castro

Asignatura: Preprocesamiento de Datos

Docente: Julián Urrea

Universidad: Universidad de La Sabana

Fecha: jueves, 20 agosto de 2026

1. Plan por problema

Problema	Dimensión	Magnitud	Estrategia propuesta	Prioridad	Semana de la Misión 2
Stock sin actualizar más de 90 días	Oportunidad	350.611 registros (54,78 %)	Crear una columna indicadora "stock_desactualizado" que marque los registros con más de 90 días sin actualización y tratarlos por separado en los análisis de inventario. Documentar el umbral utilizado para que el criterio sea reproducible.	Alta	Semana 10
metodo_pago inconsistente	Consistencia	129.372 registros (20,21 %) — 20 variantes para 4 métodos reales	Estandarización de texto: aplicar strip() y normalización de mayúsculas, y luego homologar cada variante a las 4 categorías reales (Efectivo, PayPal, Transferencia, Tarjeta) usando un diccionario.	Alta	Semana 7
Faltantes en correo_cliente	Compleitud	105.312 registros (16,46 %)	Estrategia MNAR: se creó la columna indicadora correo_cliente_imputado y no se imputa el valor. La decisión,	Alta	Semana 6

Problema	Dimensión	Magnitud	Estrategia propuesta	Prioridad	Semana de la Misión 2
			tomada en S04, se conserva en Misión 2. En esta semana se validará el impacto de los correos ausentes sobre las campañas de contacto.		
nivel_satisfaccion inconsistente	Consistencia	95.706 registros (14,95 %) — 15 variantes para 3 niveles	Estandarización de texto y homologación a los 3 niveles válidos (Alto, Medio, Bajo). Se aplica strip(), se unifica la capitalización y se corrigen tildes antes del mapeo final.	Alta	Semana 7
Correos sin @	Validez	51.532 registros (8,05 %) — formato inválido	Validación con expresión regular sobre correo_cliente. Los registros que no cumplen el formato se marcan con una columna indicadora "correo_invalido" y se excluyen de los envíos de contacto.	Alta	Semana 9
Fechas de stock futuras	Oportunidad	21.722 registros (3,39 %)	Detección de fechas posteriores a la fecha de corte y marcación como valores no válidos. Cuando la fecha sea claramente un error de digitación se corrige; en caso contrario se excluye de los análisis de inventario.	Alta	Semana 9
Filas completamente duplicadas	Unicidad	20.000 filas (3,12 %)	df.drop_duplicates() conservando la primera aparición. La eliminación se aplica sobre todo el DataFrame y se verifica con df.shape antes y después.	Alta	Semana 6
id_pedido duplicados	Unicidad	20.000 IDs repetidos (3,12 %)	df.drop_duplicates(subset=["id_pedido"], keep="first") para garantizar un solo registro por pedido. Se documenta la	Alta	Semana 6

Problema	Dimensión	Magnitud	Estrategia propuesta	Prioridad	Semana de la Misión 2
			cantidad de filas eliminadas para verificación.		
Precios negativos	Exactitud	19.629 registros (3,07 %) — valores fuera de dominio	Corrección por signo con abs() en los casos claramente atribuibles a errores de captura. Los casos ambiguos se marcan con columna indicadora y se revisan uno a uno.	Alta	Semana 8
Unidades negativas	Exactitud	18.550 registros (2,90 %) — valores fuera de dominio	Corrección por signo con abs() o exclusión según la revisión caso a caso. Se conserva una columna indicadora para trazar los registros modificados.	Alta	Semana 8
Fechas inválidas	Validez	17.061 registros (2,67 %) — formatos mezclados y fechas imposibles	Parseo tolerante con pd.to_datetime(errors="coerce") que maneja los formatos mezclados (DD/MM/YYYY, D/M/YYYY, YYYY-MM-DD). Las fechas no parseables se marcan como faltantes.	Alta	Semana 9
Fechas de pedido futuras	Oportunidad	16.485 registros (2,58 %)	Marcar los registros con fecha posterior a la fecha de corte y excluirlos de los análisis históricos de ventas. Se conserva un registro trazable de los excluidos.	Alta	Semana 9
Faltantes en comentario_cliente	Complejidad	90.806 registros (14,19 %)	Estrategia MNAR: se creó la columna indicadora comentario_cliente_imputado y no se imputa el valor. Aplicado en S04. En Misión 2 solo se valida que la decisión se conserve.	Media	Semana 6

Problema	Dimensión	Magnitud	Estrategia propuesta	Prioridad	Semana de la Misión 2
Faltantes en nivel_satisfaccion	Compleitud	46.469 registros (7,26 %)	Imputación por grupo con la moda de cada canal_compra (mecanismo MAR). Aplicado en S04. En Misión 2 se verifica que la imputación se mantenga después del resto de transformaciones.	Media	Semana 6
Faltantes en ciudad_tienda	Compleitud	29.928 registros (4,68 %)	Imputación con valor constante "Desconocida". Aplicado en S04. En Misión 2 se revisa que no se hayan introducido nuevos vacíos al homologar las ciudades.	Media	Semana 6
Edades fuera del rango 0–120 años	Exactitud	27.829 registros (4,35 %) — fuera de rango	Winsorización al rango válido [0, 120] o marcación como valor inválido según el impacto sobre la segmentación por edad. Se documenta el criterio elegido.	Media	Semana 8
Pedidos con más de 100 unidades	Exactitud	18.526 registros (2,89 %) — outlier comercial	Análisis de outliers: se compara la distribución con y sin estos registros y se decide entre winsorización o segmentación aparte para pedidos mayoristas.	Media	Semana 8
Precios superiores a \$10.000.000	Exactitud	6.164 registros (0,96 %) — outlier extremo	Detección de outliers extremos y tratamiento con winsorización al percentil 99, o corrección puntual cuando el valor sea claramente un error de digitación (ceros de más).	Media	Semana 8

2. Cierre de plan

Al aplicar este plan, el dataset de NovaMarket quedará con menos del 2 % de valores faltantes sin tratar, un formato único para las 12 ciudades donde opera la empresa y para las 6 categorías reales de producto. Los 20.000 pedidos duplicados quedarán eliminados y todas las fechas estarán validadas y en un único formato estándar. Los valores numéricos de precios, edades y unidades quedarán dentro de rangos razonables para el negocio, y los 350.611 registros de inventario con más de 90 días sin actualizar quedarán marcados de forma explícita, para que ninguna decisión operativa se apoye en información desactualizada. Con estas correcciones, el dataset pasará de una confiabilidad media a poder utilizarse en reportes de ventas, análisis de inventario y segmentación de clientes con un nivel de confianza alto.